A 股逐年因子库构建研究

研究过程、主要问题与处理办法

摘要

本文报告 A 股逐年因子库构建过程的研究方法、主要发现及其处理办法。研究对象为 A 股市场的选股因子；考虑到 A 股个股难以做空，研究只考察因子的多头一端。因子库按年构建：对 2010—2025 年的每一年，只使用上一年年末之前的数据，从约 2.4 万个候选公式与 205 个模型输出中筛选因子；入库门槛由安慰剂检验确定；筛选结果只作为候选，是否正式使用由人工决定。

研究结果表明，影响结论可靠性的主要因素不是模型结构的复杂度，而是评价口径、选择环节的处理方式与数值实现的正确性。只用一年做验收、从大量候选中取成绩最高者，都会高估因子的表现；部分基础算子存在单精度累加、并列排名与记忆长度不足等缺陷，曾使神经网络模型实际以股票代码顺序作为输入；评价、去重与入库环节采用互不一致的标准，使规则之外的情形不断出现。在修正上述缺陷，并将搜索、入库与门槛校准统一到“该因子能否提供已有因子之外的信息”这一标准之后，挖掘结果主要集中于估值类与低换手、低关注类变量，模型结构之间的差异很小。因子库层面的样本外检验尚未完成，后续工作据此确定。

关键词：A 股因子库；选股因子；安慰剂检验；前视偏差；模型稳定性

前言

本文记录的研究在一个自行开发的量化研究平台上完成，研究方式是研究者提出想法、由人工智能编程代理实现代码并运行，再由研究者对照结果判断问题所在。以下分别说明。

计算平台

- 软件：自行开发的量化研究平台 NaiveQuant（Python 编写，本文写作时为 0.36 版）。与本文有关的部分包括：数据目录（行情、估值与财报、事件、行业、宏观等数据集的统一入口）；面板计算引擎（公式语言、算子注册、因子取值与重新计算）；因子挖掘模块（公式搜索、模型训练、入库与门槛校准）；回测引擎；流程调度与资源管理（按年份、按步骤运行，记录进度，失败后可续跑）。主要依赖 PyTorch 2.8、LightGBM 4.6、DuckDB，数据以 DuckDB 与 Parquet 文件存放。
- 数据：A 股日线行情自 2000 年起；1 分钟线自 2005 年起，按月汇总为紧凑缓存；另有估值与财报、业绩预告与限售股解禁事件、行业分类、宏观与跨资产数据（中美国债收益率、人民币汇率、黄金、原油等）。
- 硬件：一台笔记本电脑，处理器 Intel Core Ultra 9 275HX（16 线程），显卡 NVIDIA GeForce RTX 5080 Laptop（显存 16G），在 Windows 的 Linux 子系统（WSL2）中运行，内存上限 22G。显卡同时供桌面使用，整卡显存占用规定不超过 15G。
- 资源管理：耗费内存或显存的任务先向平台的资源账本申领额度，额度不够时排队；运行中内存超出申领额度的任务由守护进程终止并按设定次数重试。第四轮逐年挖掘（2010—2025 年，每年依次进行公式搜索、公式入库、模型训练、模型入库、报告五步）全程约 30 小时，按此方式无人值守运行。

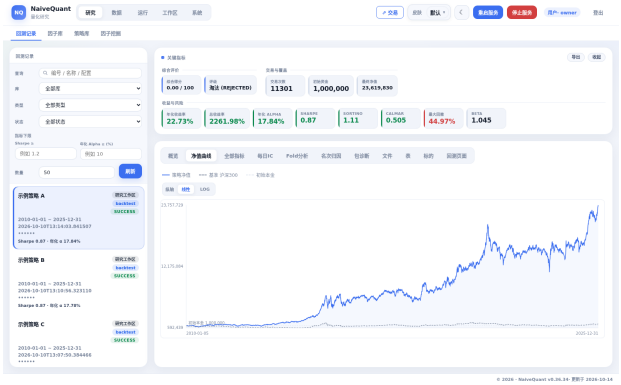
平台的主要界面见图 1：回测记录（关键指标与净值曲线）、因子库、任务（逐年挖掘流程各步骤的进度、用时与资源占用）以及数据目录。

研究方式

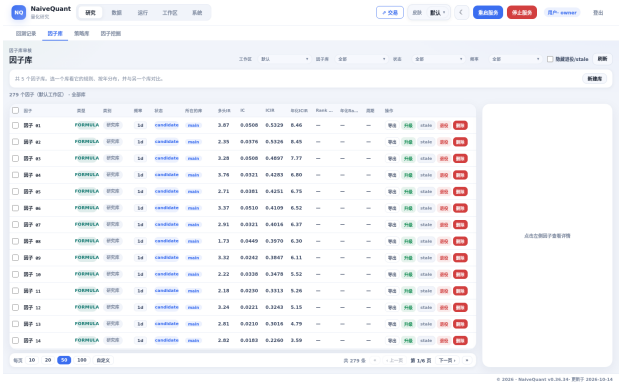
研究按“提出想法—实现与运行—对照结果判断”的循环进行（图 2）。

1. 提出想法。研究方向、评价口径、验收标准与资源约束由研究者确定。研究者阅读结果、日志与因子记录时提出的疑问，也作为下一轮工作的起点，例如“某个因子的写法是否合理”“不同随机种子的结果为何差别很大”“验收年的成绩能否预示下一年”。
2. 实现与运行。编程代理（Claude Code）负责在平台中编写代码、写测试、运行实验与挖掘流程，并把每一步的做法、数据与结果记入研究日志。平台代码的修改都经过测试与版本记录；挖掘流程运行期间的修改先在独立的代码副本中完成，经研究者同意后再替换；因子入库只到候选状态，是否正式使用由人工决定。
3. 对照结果、判断问题。研究者对照数据、日志与预期判断结果是否可信、问题出在哪里，再决定接受、修改或放弃。判断时常用的核对手段有：用另一块数据面板重新计算并逐位比较；用打乱股票与未来收益对应关系的安慰剂数据作对照；对“有无差别”一类问题做置换检验；长期结果按时间段分开查看。

第 3 章各条目中的“问题”“检验”“原因”“处理”，大多对应这一循环的一次往复。



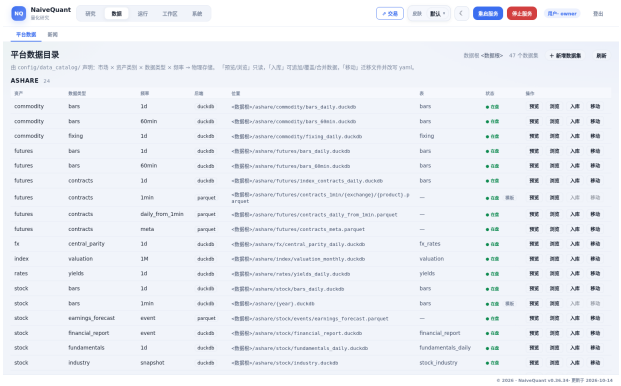
(a) 回测记录与净值曲线



(b) 因子库



(c) 任务：逐年挖掘流程的进度



(d) 数据目录

图 1　NaiveQuant 平台界面（截图中的账户名、策略与因子名称、流程名、运行编号与本地路径已作脱敏处理）

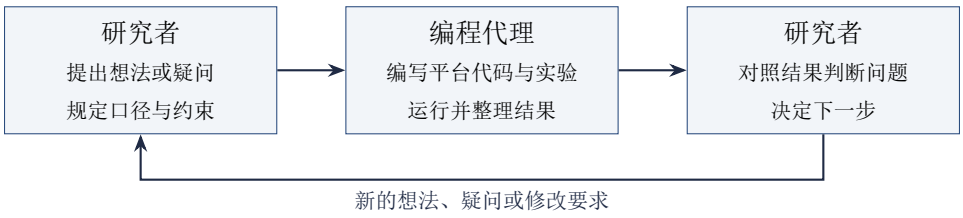


图 2　研究方式

目录

前言 **2**

1 引言 **5**
1.1 研究对象与目标 5
1.2 研究规则与记录方式 5
1.3 研究阶段 5

2 研究方法与算例 **5**
2.1 总体结构 6
2.2 逐年构建流程 6
2.3 因子成绩的计算 6
2.4 神经网络训练的目标函数 8
2.5 门槛校准：安慰剂检验 9
2.6 入库条件 9
2.7 公式搜索的方法 10
2.8 验收标准 12

3 主要发现与修正 **13**
3.1 选择效应与成绩高估 13
3.2 门槛校准与安慰剂检验 14
3.3 数据与计算正确性 14
3.4 平台实现与资源约束 15
3.5 模型结构与训练稳定性 18
3.6 搜索流程与方法 19
3.7 挖掘结果的解释 21

4 讨论 **23**
4.1 主要结论 23
4.2 问题的类型 23
4.3 处理问题的做法 24

5 结论 **24**

6 下一轮计划与展望 **24**
6.1 第四轮结束后的检验 24
6.2 下一轮的改动 24
6.3 展望 25

1 引言

1.1 研究对象与目标

本文的研究对象是 A 股市场的选股因子。由于 A 股个股难以做空，研究只考察因子的多头一端。当前的主要工作是逐年构建因子库：对 2010—2025 年的每一年，只使用上一年年末以前的数据，从约 2.4 万个候选公式和 205 个模型输出中筛选因子；入库门槛用安慰剂检验（打乱股票与未来收益的对应关系后重复整个筛选流程）确定；筛选结果只作为候选，是否正式使用由人工决定。

本文逐条说明这一过程中发现的问题的发现方式、所进行的检验、原因、处理办法，以及尚未解决的部分。

1.2 研究规则与记录方式

研究的分工与方式见前言。文中出现的阈值，均注明由研究者确定还是由本次研究自行设定。研究遵循以下规则：

- 开发段与留出段相互独立，方案确定后留出段只运行一次；收益以平台回测引擎的结果为准。
- 每次只改动一个设计因素；所有尝试（包括失败者）均记录在案。
- 参数选择以一段区间内是否稳定为依据，不以单一最优点为选择依据。
- 得出否定结论时，须写明已经检验和未曾检验的内容。
- 挖掘流程运行期间如需修改平台代码，只能在独立的代码副本中进行；暂停流程须经研究者同意。

1.3 研究阶段

研究过程共分七个阶段，各阶段的主要工作及其在本文中的位置如表 1 所示。阶段一至三是完整选股策略的研究，阶段四至七是逐年因子库的构建；第 3 章只涵盖后者。

表 1 研究阶段与本文章节

阶段	主要工作	第 3 章中的位置
一	基线策略的建立，以及择时方案与网络结构的检验	—
二	逐年滚动回测与期货对冲的检验	—
三	分段检查，研究方向由完整策略转向因子本身	—
四	逐年因子库第一版的建立	3.3
五	平台重构与第三版设计的确定	3.2、3.4
六	入库门槛校准与第一至第三轮挖掘	3.1、3.2、3.3、3.6、3.7
七	第四轮挖掘与运行期间的修正	3.1—3.7

2 研究方法与算例

本章说明逐年因子库的构建方法与各项计算，并以第四轮挖掘中的实际记录为算例。除注明者外，数值均取自第四轮的配置与候选因子记录。

2.1 总体结构

逐年因子库的构建由数据、评价、公式搜索、模型训练、入库与检验六部分组成，见图 3。

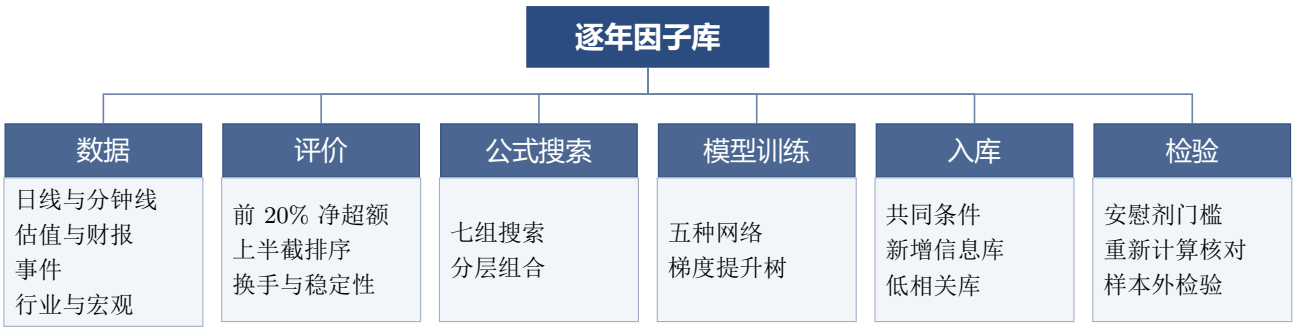


图 3 逐年因子库的总体结构

2.2 逐年构建流程

第 Y 年的因子库只使用 $Y-1$ 年年末以前的数据：公式因子在 $[Y-5, Y-2]$ 上搜索（下称挖掘段），在 $Y-1$ 年检验（下称验收年）；模型在 $[Y-5, Y-3]$ 上训练，用 $Y-2$ 年决定训练到第几轮停止，用 $Y-1$ 年决定是否入库。挖掘段与验收年末尾远期收益超出信息截止日的交易日不计入。入选的因子分别放入两个库：新增信息库要求剔除已有因子能解释的部分后仍然有效；低相关库只要求与库内因子的两两截面相关低于 0.7。两个库每年最多收录 8 个公式因子与 4 个模型因子。每年依次进行公式搜索、公式入库、模型训练、模型入库与报告五步。

2.3 因子成绩的计算

全程使用同一种评价方法：每日按因子排序取前 20% 的股票，计算其相对股票池等权平均的超额收益；第 t 日收盘后计算信号，第 $t+1$ 日收盘买入，持有 10 个交易日，单边成本按 0.18% 扣除。涉及因子在组合中是否可用的结论，以组合模拟器（计入换手、持有期与交易成本）的结果为准。

逐日计算。 设第 t 日股票池内同时具有因子值与远期收益的股票共 n_t 只（不足 301 只的交易日不计入）。

- 远期收益：第 $t{+}1$ 日收盘买入，持有 10 个交易日，$f_{i,t} = P_{i,t+11}/P_{i,t+1} - 1$，截断于 $[-50\%, +100\%]$。
- 因子在池内的百分位名次 $q_{i,t} \in (0, 1]$，相同取值取平均名次；名次高于 0.8 的股票构成“前 20%”，记为 S_t。
- 换手率：$\mathrm{to}_t = 1 - |S_t \cap S_{t-10}|/|S_t|$，即与 10 个交易日之前的前 20% 相比被替换的比例。
- 当日净超额：

$$ex_t = \frac{1}{|S_t|}\sum_{i \in S_t} f_{i,t} - \frac{1}{n_t}\sum_{i} f_{i,t} - 2c \cdot \mathrm{to}_t, \qquad c = 0.18\%.$$

- 上半截排序相关 ic_t：在名次不低于 0.5 的股票中，因子名次与远期收益名次的相关系数。由于 A 股只能做多，下半截的排序是否准确不影响实际收益，故只考察上半截。

区间汇总。 由逐日序列得到一段时间的各项指标，计算方法见表 2。

表 2 区间指标的计算方法

指标	计算方法
long_ir（多头信息比率）	$\overline{ex}/\operatorname{sd}(ex)\times\sqrt{252/10}$。每个 ex_t 是 10 日收益，一年约有 25.2 个持有期，故乘 $\sqrt{25.2}$ 而非 $\sqrt{252}$
uh_icir（上半截排序比率）	$\overline{ic}/\operatorname{sd}(ic)\times\sqrt{252/10}$；上半截内没有区分度的交易日不计入
top_to（换手率）	各日 to_t 的均值
long_ex_ann（年化净超额）	$\overline{ex}\times 252/10$
正收益年份比例	逐年计算 ex_t 的均值，取值为正的年份所占比例（一年至少 60 个计入日）
有值天数比例	计入的天数占区间总天数的比例；数据起始较晚的原料会使该比例偏低

搜索中的适应度。

$$\mathrm{fit}=\min(\mathrm{long_ir},\ \mathrm{uh_icir})-3\max(0,\ \mathrm{top_to}-0.6)-0.1\,n_{\mathrm{ops}}.$$

取两个比率中的较小者，要求“前 20% 获得超额”与“上半截排序准确”同时成立；换手率超过 0.6 的部分加重扣分；每增加一个算子扣 0.1，使成绩相近时写法简单的公式排在前面。挖掘段正收益年份比例不低于 75%、有值天数比例不低于 80% 为硬条件。搜索排序时，正收益年份比例每差 25% 扣 1.0（不直接记为最低分），使搜索能够区分差距的大小；入库时该条件仍为硬条件。搜索阶段的成绩在市值与行业中性化之后计算（中性化方法见下文）。

中性化。 先对市值做截面回归取残差，再在行业内减去行业均值，然后按上述方法计算。中性化后的成绩用于判断因子的表现是否只来自小市值或个别行业。

算例 2.1：一个公式因子的成绩。 以 2020 年进入新增信息库的因子为例：

$$-\ \mathrm{times}\Big(\mathrm{over}\big(\mathrm{ev_since}_{90}(\mathrm{amt}),\ \mathrm{amt}\big),\ \ \mathrm{resid}\big(\mathrm{lowfrac}_{120}(\mathrm{tor_free}),\ \mathrm{add}(\mathrm{amt},\mathrm{mcap})\big)\Big),$$

即“距上次成交额异常的天数除以当日成交额”与“自由流通换手率在 120 日内慢变化成分的占比（剔除成交额与市值的影响后）”的乘积，方向取反。共 6 个算子。其各项记录见表 3。

表 3 算例 2.1 的各项成绩

	挖掘段（2015—2018）	验收年（2019）	说明
long_ir（未中性化）	2.18	2.13	入库第一关用
long_ir（中性化后）	1.32	2.34	搜索与入库第三关用
uh_icir（未中性化）	4.11	4.41	
uh_icir（中性化后）	3.57	3.98	
top_to	0.38	0.36	
年化净超额（未中性化）	12.6%	11.8%	
正收益年份比例（中性化后）	75%	—	恰在硬条件上

由表中数值可以还原几项计算：

- 适应度：$\min(1.32,\,3.57) - 3\max(0,\,0.40-0.6) - 0.1\times 6 = 1.32 - 0 - 0.6 = 0.72$，与记录的 0.719 一致。
- 换手成本：每个持有期扣 $2\times 0.18\%\times 0.38\approx 0.14\%$，一年约 $0.14\%\times 25.2\approx 3.4\%$；表中 12.6% 是扣除这部分之后的数值。
- 波动：年化净超额 12.6% 对应每个持有期平均 $12.6\%/25.2 = 0.50\%$；long_ir 为 2.18，则每个持有期超额的标准差约为 $0.50\%\times\sqrt{25.2}/2.18\approx 1.15\%$。

该因子中性化后挖掘段的 long_ir（1.32）明显低于未中性化的 2.18，说明其挖掘段成绩有相当一部分来自市值或行业暴露；验收年中性化后反而更高（2.34），两段的情况不同。

2.4 神经网络训练的目标函数

“前 20%”是不可导的硬划分，训练时改用软持仓，计算步骤如下。

1. 模型对当日抽取的股票（训练时每日随机抽 1024 只）输出 8 个分数，各分数做截面标准化，得到 $z_{i,k}$。
2. 第 k 个输出的持仓权重 $w_{i,k} = \mathrm{softmax}_i(3\,z_{i,k})$。温度取 3，使权重集中于分数靠前的一部分股票。
3. 当日超额 $ex_k = \sum_i w_{i,k} f_i - \bar{f} -$ 成本$_k$，其中成本按同一批股票 10 日后的权重变化计算：$0.18\%\times\sum_i |w_{i,k}^{(t+10)} - w_{i,k}^{(t)}|$。
4. 每批 16 个交易日，第 k 个输出的夏普比率为 $\mathrm{mean}(ex_k)/\,\mathrm{sd}(ex_k)$，不做年化。
5. 损失函数为 $-\frac{1}{8}\sum_k$ 夏普$_k + 2.0\times$（8 个输出两两截面相关系数平方的均值），第二项使各输出彼此不同。

验证年（训练集之后一年）的成绩：将全年各交易日的超额拼接，每个输出计算一个夏普比率，再对 8 个输出取平均，同样不做年化。验证成绩连续 4 轮不提升即停止训练（最多 30 轮），保留成绩最好的一轮。优化器为 AdamW，学习率 0.001。该夏普比率只用于训练与选择停止的轮次；入库时，模型的每个输出与公式因子一样，按表 2 的指标在测试年评价。

算例 2.2：训练日志。 以下是 2015 年一个模型（截面注意力加因果卷积序列编码，种子 2）的部分训练记录：

```
第 4 轮：验证集上各头夏普的均值 0.526（各头 0.18 ~ 0.89，8/8 个为正）
第 10 轮：验证集上各头夏普的均值 0.938（各头 0.82 ~ 1.07，8/8 个为正）
第 11 轮：验证集上各头夏普的均值 0.658（各头 0.60 ~ 0.74，8/8 个为正）
第 14 轮：验证集上各头夏普的均值 1.195（各头 1.08 ~ 1.37，8/8 个为正）
第 15 轮：验证集上各头夏普的均值 0.729（各头 0.65 ~ 0.80，8/8 个为正）
```

“验证集上各头夏普的均值”即上述第 5 步之后的验证成绩，括号内是 8 个输出各自的范围。该模型共训练 18 轮，保留第 14 轮的参数。可以看到，同一轮内 8 个输出的成绩相近，而相邻两轮之间的变化可达 0.3 以上，因此“最好的一轮”包含较大的偶然成分（见第 3.5 节）。

模型因子的组成见图 4。

五种网络结构共用同一个截面注意力主干：当日池内每只股票作为一个位置，股票之间相互比较后打分。各结构的差别仅在于额外的输入：分组特征，或由 GRU、LSTM、因果卷积编码的近 20 日序列。每种结构训练 5 个随机种子；梯度提升树作为对照，其标签是远期收益在当日池内的名次。

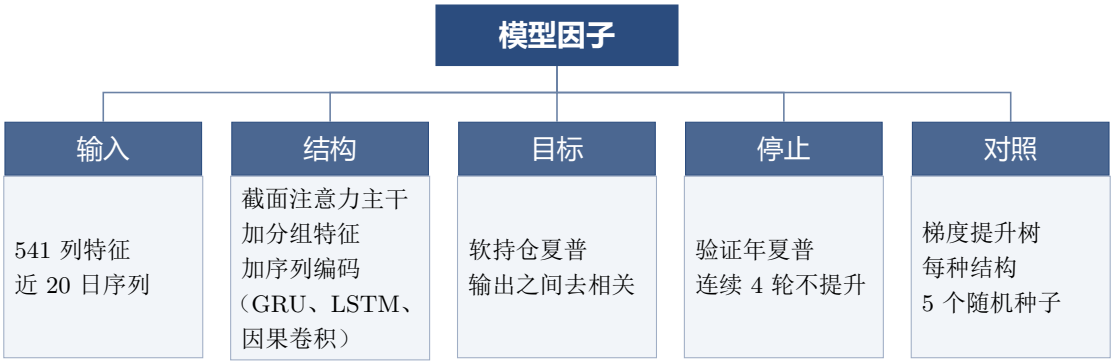


图 4 模型因子的组成

2.5 门槛校准：安慰剂检验

入库门槛不取固定数值，而由安慰剂检验确定：打乱股票与未来收益的对应关系后重复整个筛选流程，看偶然能有多少候选通过，据此确定门槛。具体步骤如下。

1. 将远期收益按 20 个交易日分块打乱：每一块随机重排股票，把一只股票这 20 日的收益整体换给另一只股票。这样保留了收益的时间结构（10 日收益相互重叠，逐日打乱会破坏这一结构，使门槛偏低），同时切断因子与收益的对应关系。
2. 在打乱后的数据上，以相同的搜索方法、预算与入围规则完整运行一遍（第四轮使用 2012、2017、2022 三个窗口）。此时任何好成绩都只能来自偶然。
3. 取以下两个条件中较严的 τ：
   - 挖掘段与验收年 long_ir 同时超过 τ 的安慰剂候选，不超过入围数的 1%；
   - 通过全部入库条件的安慰剂信号（相近写法计为一个），平均每个窗口不超过 1 个。
4. 门槛 $= (1+\tau)/2$，其中 1.0 为经验参考值。若 τ 大于 1，不给出门槛，而是先检查原因（偶然即可通过，说明搜索或入库条件存在问题）。

算例 2.3：第四轮的校准。 第四轮安慰剂运行中，入围并经验收年评价的候选共 12,545 个，按简化条件计，挖掘段通过 1.2%，验收年通过 2.95%，两段均通过的仅 7 个（0.06%）。按上述规则得 $\tau = 0.85$，门槛 $= (1+0.85)/2 \approx 0.925$。校准过程中曾出现两次异常：一是安慰剂值高达 3.8，原因是含解禁变量的公式在挖掘段只有约 11% 的交易日有值，补充“有值天数比例不低于 80%”后消除；二是安慰剂值为 1.45，原因是一个偶然表现较好的信号的各种近似写法占据了 144 个入围位置中的 143 个，改为每组每个信号只保留一个后降至 1.20，再按不同信号计数后得到 0.85。

2.6 入库条件

入库的流程见图 5。

两个库每年最多各收录 8 个公式因子、4 个模型因子。入库前以另一块面板重新计算，与挖掘时的值核对，不一致者不入库。

“剔除已有因子能解释的部分”按以下方法计算：每日将库内已有因子的池内名次（减去均值）依次正交化，得到一组相互正交的成分；候选因子的名次对这些成分逐个投影并减去投影，剩余部分即已有因子不能解释的部分。剩余方差比例为每日“剩余部分的平方和与原平方和之比”的平均；剩余部分再按表 2 的方法计算 long_ir。

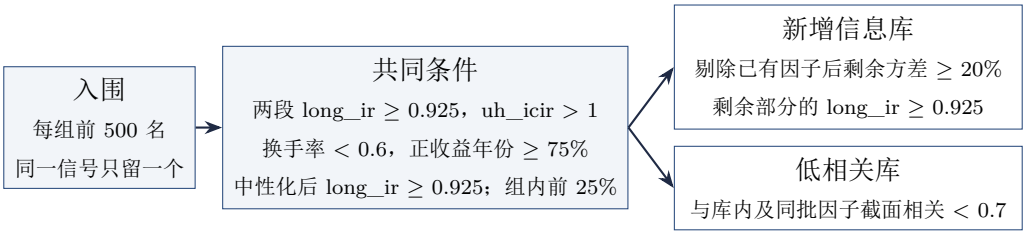


图 5 公式因子的入库流程

算例 2.4：两个库对同类因子的不同判断。

- 算例 2.1 的因子：剩余方差比例 0.828，剩余部分的 long_ir 挖掘段 1.52、验收年 1.49，均高于 0.925，进入新增信息库。2020 年通过共同条件的 361 个公式中，进入新增信息库的只有 3 个，其余 358 个均因新增信息不足而未入选；同年低相关库收录 8 个，另有 349 个因每年上限未能收录。
- 第 3.6 节讨论的异常因子 `value_at_shock(rank(B/P)+rank(beta(USDCNY)), shock=B/P, 60)`：剩余方差比例 0.72，但剩余部分的 long_ir 挖掘段 −1.21、测试集 −0.20，未进入新增信息库；而由于大量股票取值为 0，它与任何单个已有因子的截面相关只有 0.375，进入了低相关库。
- 2016 年入库日志中的一条记录：

  > 跳过 残差方差占比 =0.52 残差多头信息比率 挖掘段 =-0.71 测试集 =2.43 add(emadev40(yj_chg),ev_since250(amt))

  该公式测试集的剩余部分成绩很高（2.43），但挖掘段为负（−0.71），新增信息库要求两段都高于门槛，因此未入选。

2.7 公式搜索的方法

公式的写法。 公式由原料（约 50 种）与算子构成。一元算子 24 个，包括均值、标准差、偏度、相对变化、历史位置、距最高点的天数、事件后的反应等；二元算子 16 个，包括排名相加、相减、相乘，原始值的四则运算，滚动相关，回归系数与残差等。写法须满足以下规则：窗口只取固定档位；原始值的加减只允许在量纲相同的原料之间进行，乘除使量纲相乘或相消；同一算子不得直接嵌套于自身之外；一个公式最多 7 个算子、5 层嵌套、4 种原料。这些规则的目的是减少同一公式的不同写法，否则偶然通过的机会会成倍增加。

分组搜索。 搜索分为七组：一组使用全部原料；估值、流动性、价格形态、事件、日内结构五组各自只使用本类原料；另有一组在评分时先剔除已入库因子的影响。分组的原因是，只有一组时入围位置会被同一主题的各种写法占满（第三轮入库的 31 个公式全部含估值类原料）。

分层搜索。 先计算全部小公式，再在表现较好的小公式（下称积木）之间组合，逐层提高复杂度，结构见图 6。

1. 第 1 层：一个算子作用于一种原料的公式，每个算子取短、中、长三个窗口（全部原料一组约 3300 个），全部计算。
2. 积木池：每日前 20% 股票的超额序列相关在 0.8 以上的公式视为同一信号，只保留成绩最好的写法；每层至多保留 60 个不同的信号。

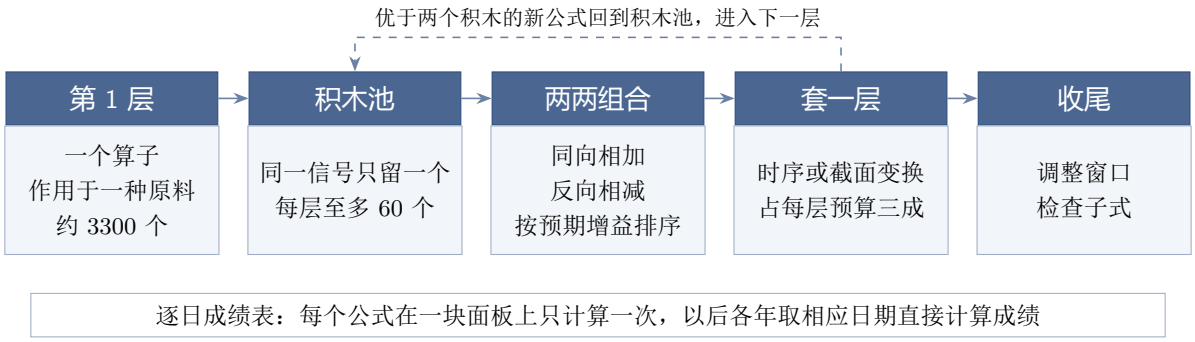


图 6 分层搜索的流程

3. 两两组合：两个积木先用一个算子试探（方向相同用排名相加，方向相反用排名相减），结果优于两个积木时，再尝试其余算子；组合的先后按预期增益排列（见下文）。优于两个积木的新公式回到积木池，参与下一层组合。
4. 套一层：对表现较好的积木再加一个一元算子（如取均值、相对变化、行业内相对），占每层预算的三成。
5. 收尾：对前几十名调整相邻窗口、更换同类算子；逐个检查各公式的子式，子式本身更好的，该公式不占入围位置。
6. 复用：每个公式在一块面板上只计算一次，逐日成绩存入成绩表；以后各年用到时，直接取相应日期计算成绩。

预期增益。 设两个积木逐日超额序列的信息比率分别为 f_a、f_b，相关系数为 ρ。若二者波动相近，等权合成后有 $\mathrm{Var}(a+b)=\sigma^2(2+2\rho)$，合成后的信息比率约为 $(f_a+f_b)/\sqrt{2+2\rho}$。以此减去较好一个积木的成绩，作为组合的预期增益：

$$g=\frac{f_a+f_b}{\sqrt{2+2\rho}}-\max(f_a,f_b).$$

两个积木均较强且相关较低的组合优先尝试；高度相关的两个积木（多为同一主题的不同写法）排在后面。该式只用于排序，组合的实际效果仍以计算结果为准。

算例 2.5：预期增益。 设 $f_a=1.5$，$f_b=1.2$。若 $\rho=0.8$，合成后约为 $2.7/\sqrt{3.6}\approx 1.42$，$g\approx -0.08$，即合成不如单用 a；若 $\rho=0.1$，合成后约为 $2.7/\sqrt{2.2}\approx 1.82$，$g\approx 0.32$。按旧的排序方法（两个成绩之和），这两个组合的次序相同；按预期增益，后者优先。（本算例数值为说明而设。）

算例 2.6：一个公式的组成过程。 算例 2.1 的因子是在 2020 年流动性一组的搜索中由两个积木组合而成的，其组成见表 4。

积木 A 与积木 B 的方向相反（A 越大越好，B 越小越好）。若按旧的做法只用排名相加试探，两者会相互抵消；按方向选择试探算子后，才会继续尝试包括原始值相乘在内的其他算子。组合后挖掘段的中性化成绩（1.32）并不高于积木 B（1.36），但上半截排序更强，且验收年成绩（2.13，中性化后 2.34）与新增信息检验（算例 2.4）均满足要求，因此入库。

算例 2.7：一组搜索各层的记录。 2020 年流动性一组的搜索日志（节选，各层名额指新评估公式数的上限）：

表 4 算例 2.6：公式的组成（2020 年，挖掘段中性化后的成绩）

层级	公式与含义	方向	long_ir	适应度
原料	`ev_since90(amt)`：距最近一次成交额异常的天数（90 日内）	正	1.42	0.54
原料	`amt`：成交额	负	0.45	0.45
积木 A	`over(ev_since90(amt),amt)`：上式除以成交额	正	1.20	0.98
原料	`lowfrac120(tor_free)`：自由流通换手率 120 日内慢变化成分的占比	负	1.31	1.21
原料	`add(amt,mcap)`：成交额与市值的排名之和	负	1.12	1.02
积木 B	`resid(lowfrac120(tor_free),add(amt,mcap))`：前者对后者截面回归的残差	负	1.36	1.06
组合	`times(A, B)`：两者原始值相乘	负	1.32	0.72

```
第 1 层：378 个公式（另有原料 6 个），best=1.59
2 个算子这一层：名额 300，新评估 309 个；60 个不同的信号，本层最好 1.81
3 个算子这一层：名额 250，新评估 259 个；60 个不同的信号，本层最好 1.99
4 个算子这一层：名额 200，新评估 216 个；60 个不同的信号，本层最好 1.99
5 个算子这一层：名额 150，新评估 163 个；60 个不同的信号，本层最好 1.90
6 个算子这一层：名额 400，新评估 409 个；60 个不同的信号，本层最好 2.15
7 个算子这一层：名额 400，新评估 406 个；60 个不同的信号，本层最好 2.23
```

可见每层评估数百个新公式，最好成绩随层数缓慢上升；但第 3 章的统计表明，挖掘段成绩随算子数上升时，验收年成绩并不随之上升，因此适应度中对算子数的扣分是必要的。

2.8 验收标准

策略层面的验收要求为：相对中证 500 指数的年化 alpha 平均达到 20%，且最近 5 年均为正、不低于 10%。即使真实 alpha 恰为 20%，连续 5 年都不低于 10% 的概率也只有约 59%，因此该标准只能作为必要条件，不能视为充分条件。

3　主要发现与修正

本章只涵盖 A 股因子挖掘部分，即逐年因子库的搜索、训练、入库与校准（研究阶段四至七）；阶段一至三的策略研究，以及择时、对冲、交易执行等策略层面的内容，不在本章范围内。各项内容均出自研究日志的记录，未改动其中的数据；凡由研究者提出的疑点，均按原意转述为书面表述，不再逐字引用。

3.1　选择效应与成绩高估

3.1.1　验收年成绩对下一年没有预测作用

问题　一个公式在 2010—2013 年每年超额均在 10% 以上，验收年 2014 年却降到 3.4%，扣除成本后接近 0，需要说明其原因。

原因　2014 年对几乎所有从 2010—2013 年数据中找出的公式都是不利的年份。

检验　验收年是否通过门槛，对下一年是否有预测作用？取成绩靠前的 3000 个公式统计，结果如表 5 所示。

表 5　按验收年分组的次年表现

按验收年分组	个数	次年年化净超额（均值）	次年为正的比例
通过门槛	740	2.80%	75%
为正但未通过	903	3.30%	79%
为负	1357	4.41%	80%

因子轮换　进一步考察能否从库中全部因子里按过去的表现挑选较好的一部分使用（53 个公式因子，2011—2016 年，每年从当时库中全部因子里挑选），结果如表 6 所示。

表 6　按不同窗口挑选因子与全部等权的比较

挑选方式	年均净超额	6 年中好于全部等权的年数
全部等权	3.95%	—
按过去 3 年取较好的一半	5.59%	6
按过去 5 年取较好的一半	5.52%	6
按过去 1 年取较好的一半	4.37%	3

现存局限　较新因子的“过去 3—5 年”包含它被选中时的挖掘段，成绩偏高；只用入库后的表现排序，优势小一些（每年多 0.7—1.3 个百分点），但 6 年中仍有 5 年更好。

3.1.2　两轮搜索的结果基本不重合，入库因子在当年多数无效

结果　2010 年入库的 10 个公式，在 2010 年当年有 7 个收益不为正，其中 5 个属于低估类，原因是同一种风格连续几年表现较好，安慰剂检验与中性化均无法排除。

结构重合度　两轮通过门槛的公式结构只有 22 个相同。以捉放法粗略估计，该年能通过门槛的结构约 2700 个，每轮只找到约 9%。

结论　样本内都无法解释的现象，无法用于样本外的推断。

3.2 门槛校准与安慰剂检验

3.2.1 引入安慰剂检验

数据 网络因子的验收段 long_ir 中位数为 5.83，样本外为 2.94；公式因子分别为 2.89 与 0.80；按残差验收的成绩与样本外成绩的秩相关只有 0.33。

处理 入库门槛改由安慰剂检验确定，并按第 2.5 节所述以 20 个交易日为一块打乱股票与未来收益的对应关系。

3.2.2 第一轮门槛过严，挖掘没有结果

现象 第一轮挖掘 6.5 小时，2011—2016 年几乎没有公式因子入库；安慰剂在 2015 年窗口得到的验收信息比率也偏高。

原因一 各窗口的 99 分位数主要取决于哪几类公式偶然表现较好，属于估计误差，不宜按年份插值。

原因二 两段各取 99 分位数并要求同时通过，联合误入率只有 0.04%—0.47%，明显严于 1%。

其他发现 约 45% 的入围位置被只改了窗口长度的相近公式占用；`min(min(eps))` 这类等价嵌套占 2010 年通过公式的 29%。

处理 窗口改为固定档位，禁止同一算子自身嵌套，按整套条件的联合通过率校准。安慰剂值高于 1.0 说明存在问题，此后规定：安慰剂值大于 1 时先查明原因，不提高门槛。

3.2.3 第四轮门槛校准：安慰剂值从 3.8 降到 0.85

问题一 安慰剂值曾达到 3.8。安慰剂中得分较高的公式均含解禁变量，在挖掘段只有约 11% 的日期有数值，而配置中漏写了“有数值的日期不低于 80%”这一条件。

问题二 安慰剂值为 1.45：一个偶然表现较好的信号的各种近似写法占了 144 个入围位置中的 143 个。改为每组每个信号只保留一个后，降至 1.20。

问题三 判定按公式个数计数，与入库时的去重标准不一致，改为按不同信号计数（该修改在研究日志中注明是在看到结果之后作出的）。

结果 安慰剂值 0.85，门槛定为 0.925，第四轮据此开始运行。

3.3 数据与计算正确性

3.3.1 逐年因子库第一版的四类问题

知识上的前视 部分公式构造（如“聪明钱”指标）在 2018 年以后才发表，用于 2010 年的因子库属于前视，因此只保留基础变量。

入库条件过宽 第一年试运行时 84% 的候选通过，入库的 5 个中有 4 个结构相同（均为小市值）。增加市值中性化、分位数门槛与同批相关上限后重新运行。

数值误差 时序标准差在单精度下按 $E[x^2]-E[x]^2$ 计算，市值 5 日标准差的中位相对误差达 100%，改用双精度。

未接入平台 研究工作区的入库流程从未调用平台的入库函数，平台因子库始终为空，现已补上同步。

3.3.2 端到端核对失败：两个基础算子有误

现象 同一天的 541 个特征，在训练面板（从 2006 年开始）和平台重新计算的面板（从 2010 年开始）上，有 255—285 列不一致。

原因一 时序均值用单精度从面板第一天开始累加，结果随面板起点不同而变化。

原因二 截面排名遇到相同值时按列的位置排名次，而列按股票代码排序。涨跌停标记 97% 为 0，名次实际上等于代码顺序。

影响 49 列特征与修正后的秩相关低于 0.9，涨跌停相关特征只有 0.09—0.14，即原有的网络模型实际上以“股票代码顺序”作为输入。

处理 两处修正后，不一致的列数为 0。同时修正了序列输入“每 4 列取 1 列”的错误。

3.3.3 已入库公式重新计算的结果不一致

现象 第三轮 2013 年入库的 9 个公式中有 5 个重新计算核对不合格，最差的一个逐日排名相关最低为 0.867。

原因 预热天数固定为 400 天；指数均线遇到缺失值时没有有限的记忆长度；面板开头使用不完整的历史计算；入库流程未调用核对。同时发现模型训练的面板只向前保留约 145 天，而特征最长需要 329 天。

处理 每个算子登记记忆长度，嵌套时相加；指数均线截断；面板开头记忆长度不足的行不给出数值；入库前自动以另一块面板重新计算核对；增加“更换起点结果不变”的测试，覆盖全部算子。

3.3.4 入库前重新计算不一致，流程停止

现象 2015 年公式入库失败：选出的 8 个公式保存后，按规定用另一块面板重新计算核对，其中 1 个（`add(emadev60(yj_chg),emadiff20(unl20))`）不一致。

核对的意义 入库的因子以后要能在任何时间、任何面板上算出相同的数值，否则以后使用的就不是当初评价的那个因子。

处理 原为整年报错停止，改为只去掉不一致的公式，各库重新选择、重新保存。重新运行后第二批 8 个全部通过（平均秩相关最低为 0.99998）。

原因 该公式不一致的原因是指数均线的权重无限延伸，截断后的数值随面板起点有极小差别，排名后变成名次差异。

3.3.5 “训练时与已有因子去相关”始终未生效

发现 更换去相关的对象后，模型权重文件的哈希完全相同。

原因 股票池外的缺失值乘 0 仍为缺失，统一置 0 后，已有因子的矩阵全部为 0，损失函数中这一项始终为 0。前三轮均受影响（入库时的两道去重不受影响）。

处理 已在平台中修正。

3.4 平台实现与资源约束

第四轮运行期间暴露的平台问题集中在资源上限、计算入口不一致与模型可重算性三处。

3.4.1 训练好的模型无法重新计算

发现 新结构的网络因子保存后无法重新推断，正式挖掘进行到第二年即会出错。处理须在平台中进行，不在研究脚本中做临时修补。

未采纳的方案　未采纳交叉拟合，理由是：当年的 alpha 会比往年少，当年筛选出的因子在往年的适用性较强，反之则不然。

处理　平台增加“冻结信号”：保存定义与权重的哈希，规定可用的起始日期（早停年份之前的值不提供），并支持重新计算核对。

3.4.2　界面与命令行算出的门槛不同

现象　界面中“门槛校准”一栏显示安慰剂值 1.25，高于锚点 1.0，即纯运气即可使两段同时超过 1.0，故不给出门槛值；而命令行计算的安慰剂值为 0.85，门槛为 0.925。

检查　原因有两层：一是所打开的界面服务仍在运行一天半以前的旧代码，当时按公式个数而非按不同信号计数；二是改用新代码后界面仍算出 1.15——两边均从候选库读取一条“校准设置”记录，而安慰剂运行从不写入该记录，命令行读取不到时改读配置文件，界面没有配置文件可读，因而少算了三个入库条件。

处理　校准的输入改为只有一种读取方式，命令行与界面共用；入库条件取评价安慰剂候选时实际使用的那一套；条件不一致时报错；输出中列明所使用的条件。

核对　命令行结果仍为 0.85 与 0.925，调试界面显示相同。

3.4.3　内存占用与运行速度

预警　按各年股票数推算：模型训练的显存每多 1000 只股票约增加 2.2G，2018 年起会超出；模型入库一步的内存 2016 年已到 12.2G（曾被资源守护程序终止一次），2020 年前后将超过机器可提供的约 13G。

排除的办法　让模型入库只加载“验收年加预热期”的短面板不可行：低相关库的相关检验和新增信息库的残差计算使用“挖掘段加验收年”的日期，换短面板会改变入库结果。

处理　模型输出改为按时间分段重新计算（每段单独加载带预热期的小面板），结果存为临时文件。用真实数据核对 28 个输出：有数值的位置完全一致，逐日秩相关最低为 0.999997；内存由 9.5G 降至 5.7G。数值不是逐位相同（网络按 4 天一批计算，分批方式随面板起点变化），已向研究者说明。

速度检查　先分环节计时，实测（40 个公式）结果如下：

```
算子求值 199.4 ms   规模回归 16.2   行业·排名 19.8   行业·分组 44.5   打分 68.3
现在合计 344 毫秒 → 新做法 238 毫秒（1.45 倍）；固定环节（中性化 + 打分）144 → 40 毫秒
逐位核对：40 个公式里不相同的 0 个
```

进一步处理　中性化和打分每一步只用当天的截面，因此改为只在当年用到的日期上计算，三种目标的结果逐位相同；第一版设计按年份分开存储逐日成绩，实测后发现跨年复用更省时间，改为把需要存储的公式算到这块面板最后一年要用的日期。

仍然较慢　剩余的主要耗时是算子求值。为此提出三个选择（只调整求值顺序；在此基础上按年份截短面板，结果在末位有差别；减少搜索数量，会改变结果），选择前两项都做。截短面板上线前的核对（2019 年，40 个公式）：

```
旧：面板 4046 天 × 5432 只；每个公式 199 毫秒；显存峰值 9.5G
新：面板 2557 天 × 3758 只；每个公式 91 毫秒；显存峰值 5.3G
逐日序列：最大绝对差 ex 1.19e-07、ic 8.94e-08、to 0、n 0
成绩：方向不同的 0 个；适应度最大差 4.77e-07；验收年多头信息比率最大差 9.54e-07
```

公式搜索各年用时如图 7 所示。

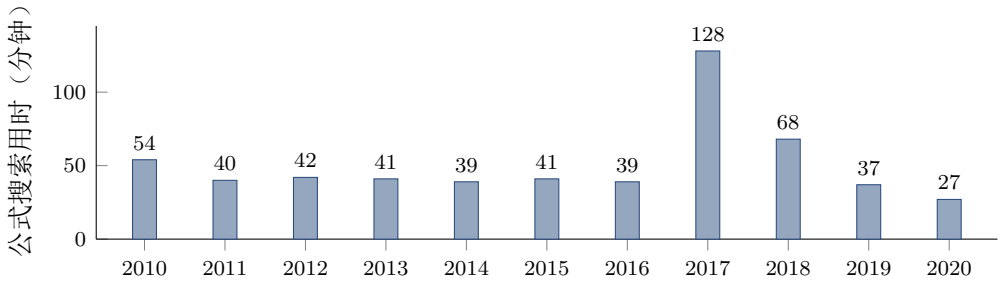


图 7 公式搜索各年用时

说明 2017 年起换用更大的面板（数据量为原来的 2.2 倍）；2018 年起只在用到的日期上打分；2019 年起使用截短的面板（2019 年是第一年，没有可复用的记录）。每年全部步骤的用时：2017 年 3 小时 39 分，2018 年 2 小时 20 分，2019 年 1 小时 45 分。

3.5　模型结构与训练稳定性

3.5.1　神经网络更换随机种子后结果差异较大

问题一　不同随机种子的相同输出本应接近或相同，实际差异较大。为回答该问题，以每个模型保存的参考值（测试年份中 12 个交易日、每日约 1900 只股票）计算不同种子之间的截面相关，结果如表 7 所示。8 个输出在训练中只要求各自成绩较好、彼此不同，编号本身没有含义；但即使不按

表 7　不同随机种子之间的截面相关（中位数）

	树模型（1 个输出）	五种神经网络（各 8 个输出）
编号相同的输出	0.91—0.93	0.21—0.28
在另一个种子中找最接近的输出	—	0.44—0.55
8 个输出取平均后	0.91—0.93	0.57—0.67

编号对应，最接近的也只有 0.5 左右。

问题二　该结果可解释性不足、不可复现且不稳定，难以作为训练结果的依据。同一种子重新训练结果完全一致，更换种子则差异很大。对此的处理是：不以训练时的成绩为准，而以入库后的实际表现为准。

问题三　各种子输出中不相同的部分究竟属于增量信息还是噪声？为此将每个种子的输出分为“其余四个种子的平均所能解释的部分”与“该种子独有的部分”，并与实际的后续收益比较；为避免计算方法本身引入偏差，另外构造“共同部分加纯噪声”的模拟数据，以同一方法计算，结果如表 8 所示。

表 8　种子独有部分与纯噪声模拟的对比

神经网络	全截面排序相关	前 20% 的 10 日超额
单个种子	0.085 ± 0.008	$0.77\% \pm 0.09\%$
五个种子平均	0.111 ± 0.010	$0.85\% \pm 0.10\%$
种子独有的部分（实际）	0.010 ± 0.002	$0.48\% \pm 0.05\%$
种子独有的部分（纯噪声模拟）	0.022 ± 0.002	$-0.08\% \pm 0.02\%$

结论　在全截面排序上，独有部分与噪声没有区别；在前 20% 的股票上，独有部分有正的超额。入库单位改为“种子平均后的模型”。

3.5.2　训练过程的检查发现三个问题

训练日志　以 2015 年 xsttcn 结构、种子 2 的训练日志为例（节选）：

```
第 4 轮：验证集上各头夏普的均值 0.526（各头 0.18 ~ 0.89，8/8 个为正）
第 10 轮：验证集上各头夏普的均值 0.938（各头 0.82 ~ 1.07，8/8 个为正）
第 11 轮：验证集上各头夏普的均值 0.658（各头 0.60 ~ 0.74，8/8 个为正）
第 13 轮：验证集上各头夏普的均值 0.920（各头 0.83 ~ 1.06，8/8 个为正）
第 14 轮：验证集上各头夏普的均值 1.195（各头 1.08 ~ 1.37，8/8 个为正）
第 15 轮：验证集上各头夏普的均值 0.729（各头 0.65 ~ 0.80，8/8 个为正）
```

问题一：监测指标是否合理　查看损失函数：8 个输出的目标相同，提前停止所看的均值就是训练

损失在验证集上的对应量，两者一致。真正的问题是“最好的一轮”可能是偶然的高点（如上例中的第 14 轮）。

问题二：训练步长偏大 按日志拆分时间，逐轮训练占训练环节的 78%—81%；每轮只有约 45 步，验证成绩每轮变化 0.1—0.2。减小步长需要增加轮数，学习率降为三分之一则整轮要多 13—18 小时。

问题三：成交时点缺乏依据 查明该设定是本项目自行确定的，并非研究者规定；硬性限制只有“不能早于次日开盘”。

3.5.3 五种网络结构之间没有显著差异（置换检验）

问题 五种网络结构在种子平均后相关约 0.8，曾打算减少几种以节省时间，但相关系数表不足以证明结构之间没有显著差异。

检验 把问题写成可检验的形式：同一结构不同种子之间的相关，是否高于不同结构之间的相关？用置换检验（随机打乱结构标签）：

- 同结构 0.5225，跨结构 0.5116，相差 0.0109（95% 区间 0.0092—0.0125），$p = 0.36\%$；方差分解：共同部分 51%，结构 1%，种子 48%；
- 只有带分组输入的一种结构确有差别（$p = 0.008$—0.024），其余四种之间与更换种子没有区别（$p = 0.22$—0.83）；树模型与任一网络比较 $p = 0.008$，说明该方法能检出真实差别。

进一步检验 在近年（2022 年窗口）的预试中，带序列输入的结构比纯截面结构高 0.81（$p = 0.005$）。

处理 第四轮照常训练五种网络结构。

3.6 搜索流程与方法

3.6.1 公式搜索框架的确定

未采纳的方案 仅做两两组合，可能错失潜在的三元因子；经研究者建议，将算子本身与搜索算法拆分为算子、搜索空间、搜索算法三层。

处理 增加原始值的四则运算与量纲规则，多变量结构通过嵌套表达；增加对退化表达式的判定；重新进行门槛校准。

3.6.2 一个异常因子与入库标准的统一

现象 一个已入库因子的构造为 `value_at_shock(rank(B/P) + rank(beta(USDCNY)), shock=B/P, 60)`，其最外层算子被认为使用不当。

检查 该因子的含义是：当市净率倒数偏离自身 60 日均值超过 2 倍标准差时记为一次“异常”，取最近一次异常当日的“估值排名与汇率敏感度排名之和”，60 日内无异常的股票记为 0。账面价值仅在财报日变化，因此此处的“异常”实际上对应股价大幅波动。该因子在两个库中的入库记录为：

- 新增信息库未接受：剔除已有因子能解释的部分后，剩余部分的方差仍占 72%，但剩余部分的多头信息比率在挖掘段为 -1.21、在测试集为 -0.20，即其成绩全部来自与已有估值因子重合的部分；
- 低相关库接受：大量股票取值为 0，使其与任何单个已有因子的截面相关只有 0.375，低于 0.7 的上限。

原因 搜索、入库与门槛校准各自使用不同标准，且均只衡量单个因子本身的优劣，未衡量其对因

子库的增量贡献。搜索只看单个公式的成绩，因此一个强信号的各种写法都能得到高分；入库时再用相关性、数量上限、分组等办法筛选，总有遗漏。

决定 搜索、入库与门槛校准统一依据同一标准：该因子能否提供已有因子之外的信息；入库数量取决于实际找到的此类信号个数，不预先规定数量；最终以因子库合成后的下一年成绩进行检验。

3.6.3 公式同质化与搜索算法的两处缺陷

问题 “剔除已有因子的影响后再搜索”的那一组并未更分散：复杂公式前 100 名中，最常见的变量出现在 97—100 个公式里。

积木使用情况 小公式（记为“积木”）的统计结果为：

- 每年约 4700 个小公式中通过门槛的有 209—439 个，按相关低于 0.4 计算，互不相同的只有 9—15 个；
- 60 个积木中，前 10 个占全部组合使用次数的 54%—85%，第 31—60 个平均每个只用 0—2 次，问题不在数量少，而在后面的用不上；
- 两个积木方向相反（一个越大越好、一个越小越好）的组合占 42%（242 对）。搜索先用“排名相加”试探组合，相加后的平均成绩为 −0.87，没有一对好于两个积木本身；“排名相减”一次也没有试过（0/242）。

原因 搜索代码对每对积木先用相加试探，若结果不如积木本身就放弃这一对。方向相反时相加会相互抵消，必然失败，因此只有方向相同的积木能组合在一起；而估值类积木大多是“越大越好”，最容易组合。此外，组合顺序按两个积木的成绩之和排列，不考虑二者的相关。

修复方案 一是按方向选择试探方式：同向相加，反向相减；二是按预期增益排列组合顺序（f 为两个积木的信息比率，ρ 为二者逐日多头超额的相关）：

$$g = \frac{f_a + f_b}{\sqrt{2 + 2\rho}} - \max(f_a, f_b).$$

是否改用四则运算全试 按评估次数计算：每对都全试约需 21 次评估，只能试 20 对左右；单次试探可以筛选 300—500 对；已全试过的 228 对中，82% 最好的写法就是相加。但这 228 对都是相加已经成功的组合，样本有偏，因此另作检验。

检验 2010 年随机抽取试探失败的组合，同向、反向各 100 对，16 个二元算子全部计算：反向组合中，相减好于两个积木的有 40 对（任一算子 49 对）；同向组合中，换用其他算子可以挽回 26 对（主要是原始值相乘）。小规模试运行：好于两个积木的组合由 89 个增至 129 个，最高成绩由 2.00 升至 2.25。

处理 两处修复自 2017 年起生效，门槛 0.925 不重新校准，前后年份的差异记入步骤记录。

3.6.4 “放量之后”一类特征能否搜索到

问题 成交量变化趋势可能反映较多信息，例如突然放量之后的变化；需要检查这类特征是否可以由搜索框架表达并生成。

检查 把 19 种“放量之后”或成交量结构的特征逐个写成平台的公式，用搜索空间的规则检查：15 种可以生成，4 种不能（趋势斜率算子未加入搜索空间；“异常次数”需要窗口为 1；“当前成交量相对异常当天”被退化规则排除；“只算放量不算缩量”无法表达，因为异常的定义是双向的）。

未被评估的原因 可以生成的那些，七年中几乎没有被评估过：它们单独的成绩不高，进不了积木池，组合时也就轮不到。

改进方向 问题的实质是搜索只沿着单独成绩好的方向走。不依赖人工预设的办法有：对小公式完全枚举（两个变量一个算子共 56,706 个，现在每组搜索每年只评估约 500 个）；积木池按结构类型分组，每组都保留一部分；按各类组合以往的效果分配预算。

扩大搜索范围的影响 用第四轮的安慰剂候选检验扩大搜索范围是否会增加偶然通过：12,545 个入围候选中，挖掘段通过 1.2%，验收年通过 2.95%，两段都通过的 7 个；验收年是否通过与搜索成绩无关（秩相关 0.007）。搜索范围扩大后，偶然通过的只按比例增加，约 97% 仍会在验收年被排除。

3.7 挖掘结果的解释

3.7.1 成绩较好的因子都含估值变量

问题 当年筛选出的因子绝大多数含有 B/P、E/P 等估值变量，此处所指为信息比率较高的因子。

核实 第三轮入库的 31 个公式全部含估值类变量；IR 不低于 1.6 的 852 个候选全部含估值类变量。

原因 第三轮没有沿用第二轮的分组搜索；“不低于入围者 75% 分位数”这一条件以估值类的水平衡量其他类别。

处理 恢复按变量类别分成七组的搜索，分位数改为在各组内部比较，并增加一组“剔除已有因子的影响后再搜索”，随后重新校准。

3.7.2 大部分评估得到同一个低分，改按“信号”计数

现象 每年约 1.5 万次评估中，83%—88% 因“正收益年份不足”直接记为 −9 分，搜索无法判断方向。改为按差距扣分，并增加逐日成绩表与分层搜索。

验收目标有误 第一版分层搜索按公式结构仅能找回 5%。改按信号计数（截面相关不低于 0.7 视为同一信号）后：三次搜索的 851 个公式只有 49 个信号，约 10 个独立方向，且几乎都属于“低估”和“低换手、低关注”两类。

算子数量 按算子个数分组考察挖掘段表现最好的 10 个：挖掘段成绩由 1.2 升到 5.0，验收段始终在 0.5—1.4 之间。算子上限维持 7 个。

3.7.3 各年的搜索路径是否相似

问题 若各年按相近路径演化，则高层因子的变化会十分有限。

检验 就 2010—2015 年六组搜索的结果，比较相邻年份之间的重合程度，结果如表 9 所示。

表 9 相邻年份与相隔五年的搜索重合程度

	相邻两年	相隔五年
1 个算子的子公式：相同的比例	51%	20%
2 个算子的子公式：相同的比例	20%	1%
复杂公式前 100 名：公式相同 / 结构相同	1% / 2%	0% / 0%
复杂公式前 100 名所用变量的相似度（1 为相同）	多数 0.8—0.99	0.12—0.59

结论 写法逐年几乎全部不同，但所用变量相近。

3.7.4 模型是否学到了公式没有表达的结构

问题 树模型或神经网络是否已经提取到相关的公式特征，却无法表达为公式？神经网络能否转化为公式因子？

检查 拆开 2010—2016 年的 35 个树模型，按每次分裂带来的改进统计：日内结构 15%，涨跌停 15%，宏观敏感度 11%，事件 10%，估值只有 7%（而公式因子库中估值类最多）；92% 的改进来自在上一层分裂条件下的再分裂，其中 87% 跨越不同类别的变量；最常见的上下层组合是“成交额 20 日波动”与“自由流通换手率”。

3.7.5 2020 年找到的一个交互因子

结果 候选库中对应的公式为 `times(over(ev_since90(amt),amt), resid(lowfrac120(tor_free), add(amt,mcap)))`（方向取反），在流动性类变量的搜索中找到，已进入新增信息库。其挖掘段成绩为 2.18，验收年为 2.13，中性化后为 2.34，换手率为 0.38。

构造 该因子由两部分相乘：一是“距上次成交额异常的天数”除以当前成交额，二是“换手率中慢变化成分的占比”相对同规模股票的高低。

意义 这与拆解树模型时看到的跨类交互属于同一类型。

现存局限 该因子不区分放量时价格是涨还是跌，不等于“放量上涨”；目前只有挖掘段和一年验收的成绩，且是从约 2.4 万个候选中选出的，入库后的表现要等样本外检验。

4 讨论

4.1 主要结论

将研究中发现的问题按性质归并，可得以下结论。

1. 用一年数据作验收，主要反映的是那一年的市场情况。验收年是否通过门槛，与下一年的表现关系不明显：通过门槛、为正但未通过、为负三组的次年净超额分别为 2.80%、3.30%、4.41%，次年为正的比例分别为 75%、79%、80%。

2. 从大量候选中挑选，会抬高入选者的成绩。2010 年入库的 10 个公式，在当年有 7 个收益不为正；两轮搜索通过门槛的公式结构只有 22 个相同。在安慰剂数据上，搜索成绩与验收年是否通过无关（秩相关 0.007），因此门槛须由安慰剂检验按整套条件的联合通过率确定。

3. 深度模型对训练细节高度敏感。不同随机种子的相同编号输出，其截面相关只有 0.21—0.28；五种网络结构在种子平均后的相关约为 0.8，置换检验显示结构只解释 1% 的方差，种子解释 48%。因此入库单位改为“种子平均后的模型”，且不以训练时的成绩为准。

4. 数值实现与时点口径的缺陷会直接改变结论。单精度累加使时序统计量随面板起点变化；并列值的截面排名实际按股票代码排序，使网络模型以代码顺序作为输入；预热天数不足与指数均线没有有限的记忆长度，使已入库公式重新计算时 9 个中有 5 个不合格；训练时“与已有因子去相关”一项因缺失值处理不当始终为 0。

5. 评价、去重与入库采用互不一致的标准时，规则之外的情形会不断出现。典型的例子是“两两相关低”与“有新增信息”两套标准：一个因子因大量股票取值为 0，与任何单个已有因子的相关只有 0.375，从而通过低相关库的检验，而其多头信息比率全部来自与已有估值因子重合的部分。将三者统一到“该因子能否提供已有因子之外的信息”之后，挖掘结果主要集中于估值类与低换手、低关注类变量，约 10 个独立方向，模型结构之间的差异很小。

6. 工程约束会直接影响可实现的研究方案。模型训练的显存每多 1000 只股票约增加 2.2G，模型入库的内存在 2016 年已达 12.2G。将模型输出改为按时间分段重新计算后，内存由 9.5G 降至 5.7G，有数值的位置完全一致，逐日秩相关最低为 0.999997；将面板按年份截短后，单个公式的求值时间由 199 毫秒降至 91 毫秒。

4.2 问题的类型

上述问题可按性质分为四类，各类型的典型例子如表 10 所示。

表 10 问题的类型及其典型例子

类型	本文中的例子
使用了未来信息	窗口末尾的远期收益超出信息截止日；面板开头用不完整的历史计算；2018 年以后才发表的公式构造用于 2010 年的因子库
挑选导致成绩偏高	从大量候选中取最高者；神经网络从 200 个输出中选最高者；只用一年做验收
两处标准不一致	评价看多头收益、去重看全截面相关；界面与命令行读取校准设置的方式不同；“两两相关低”与“有新增信息”
工程与实现问题	训练好的模型无法重新计算；入库后重算结果不一致；内存占用逐年增长

4.3 处理问题的做法

面对上述问题，本项目逐步形成了以下做法。

- 先统计后下结论。入库数为零时，逐项统计每个条件排除了多少样本；运行速度偏低时，先分环节计时（实测表明主要耗时在算子求值）；判断“有无差别”时，先写成可检验的假设，再做置换检验。
- 对照组须与实际数据按同一方法处理。例如拆分“各种子独有的部分”时，另外构造“共同部分加纯噪声”的模拟数据，并按同一方法计算，以免计算方法本身引入偏差。
- 发现个别异常因子时，不针对该因子增加限制，而是检查入库规则为何会接受它。最终将搜索、入库与门槛校准统一到同一标准：该因子能否提供已有因子之外的信息。
- 修改分为两类：会使前后年份结果不一致的，留到下一轮；不影响结果的，在流程运行期间替换，替换前用真实数据逐位核对；无法逐位一致的，说明差异量级，由研究者决定是否采用。

5 结论

本文整理的问题表明，在逐年因子库的构建中，制约结论可靠性的因素主要来自评价口径、选择效应的处理与数值实现，而非模型的复杂度。修正这些因素之后，因子的成绩下降，但对其来源的解释变得明确：当年可用的信息主要集中于估值类与低换手、低关注类变量，模型结构之间的差异很小，网络因子的贡献主要来自多种子的平均，而非单个输出的独有部分。

6 下一轮计划与展望

第四轮运行期间发现的问题中，凡修改后会使前后年份的结果不一致的，均未在本轮改动，而是留到第四轮结束之后。以下按先后次序列出。

6.1 第四轮结束后的检验

1. 因子库层面的样本外检验。目前所有入库因子的成绩均来自挖掘段与一年验收。第四轮结束后，每年年底的因子库按固定方法合成，考察下一年的多头超额，按“仅公式”“加入树模型”“加入神经网络”三种情形及 2010—2016、2017—2025、2023—2025 三个时间段分别报告；新增信息库与低相关库并列比较。本文所述各项修改是否改善了因子库，以该检验的结果为准。
2. 因子的使用方式。按过去 3—5 年表现从全库中挑选较好一半的规则（第 3.1 节），以及神经网络“单个输出”“种子平均”“各种子分别取前列再合并”几种用法（第 3.5 节），放入上述检验中比较。
3. 按“新增信息”校准门槛。以安慰剂候选对真实因子库剔除已有因子后的成绩分布，确定新增信息这一关的门槛。
4. 网络结构的分时期检验。按早年、中期、近年三个时间段重做第 3.5 节的置换检验，据此决定下一轮保留哪几种网络结构。

6.2 下一轮的改动

1. 统一标准。搜索、入库与门槛校准都以“能否提供已有因子之外的信息”为标准（第 3.6 节）；入库数量由实际找到的此类信号个数决定，不预先规定。

2. 公式搜索。对“一个算子作用于两种原料”的小公式完全枚举（约 5.7 万个，一次性约需 1—5 小时显卡时间）；积木池按结构类型分组，每组保留一部分；按各类组合以往的效果分配预算；补充“在某一条件下看另一变量”的条件类算子，以及趋势斜率等尚未加入搜索空间的算子（第 3.6 节）。

3. 把模型学到的结构转为公式。树模型中改进最大的上下层组合作为搜索优先尝试的组合；以多个种子平均、并剔除已有因子影响后的神经网络输出为目标搜索公式（第 3.7 节）。所得公式照常通过全部入库条件。

4. 算子修正。指数均线截断造成的重新计算差异（第 3.3 节）在下一轮修正；该修改会改变所有使用指数均线的因子的数值，因此不在本轮进行。

5. 模型训练。尝试不增加训练时间的稳定办法，如学习率先大后小、参数滑动平均（第 3.5 节）；对照借鉴 AlphaNet 设计的特征，以及更换训练目标的效果。训练时“与已有因子去相关”一项已修正，下一轮仍不启用。

6. 标签的成交时点。现行标签为次日收盘买入，需要修改；具体时点待择时方案确定后一并确定，并在开始下一轮之前定下，因为它决定整轮因子的评价方式。

各项改动先在同一年、同一批数据上做一年期对照实验，每次只改动一项，比较的指标事先确定为：通过共同条件的不同信号数、进入新增信息库的个数、成绩前列公式所用变量的集中程度、因子库合成后的下一年成绩，以及同一设置下安慰剂两段都通过的信号数。按对照结果确定配置后，用最终配置重做安慰剂校准，再开始下一轮逐年挖掘。

6.3 展望

本轮的经验表明，因子挖掘中最需要防范的是评价与选择环节带来的高估，而不是模型能力的不足。下一轮在扩大搜索覆盖面的同时，将以因子库合成后的样本外成绩作为唯一的总体评价，并继续以安慰剂检验控制偶然通过的比例。